

**FLUXO DE DADOS, ETL INCREMENTAL E PADRÃO STAR SCHEMA
UTILIZANDO PYTHON: ANÁLISE E CRIAÇÃO DE INDICADORES
ESTRATÉGICOS ESTRUTURADOS EM DATA WAREHOUSE**

*DATA FLOW, INCREMENTAL ETL AND STAR SCHEMA PATTERN USING PYTHON:
ANALYSIS AND CREATION OF STRATEGIC INDICATORS STRUCTURED IN A
DATA WAREHOUSE*

Matheus Diirr Aguiar Veiga de Souza¹

Kayo Gabriel Soares da Silva²

Ruan Gustavo Soares da Silva³

Gabriel Pereira Góes⁴

JAMES JUNIOR⁵

RESUMO: Este trabalho apresenta o desenvolvimento de uma solução de Engenharia de Dados aplicada ao esquema de Recursos Humanos do banco de dados AdventureWorks, utilizado como fonte transacional em SQL Server. O objetivo foi construir um Data Warehouse multidimensional capaz de organizar os dados para análises estratégicas, utilizando o padrão Star Schema e um processo de ETL incremental. A metodologia compreendeu a análise e o mapeamento do modelo relacional de origem, a definição do modelo multidimensional, sua implementação no PostgreSQL e a construção de uma ETL em Python, com extração dos dados, persistência intermediária em arquivos CSV, transformação e carregamento no Data Warehouse. Para as atualizações subsequentes à carga inicial, foi adotada uma estratégia incremental baseada na data de modificação dos registros, com controle por meio da tabela *dw_metadata*. Como forma de validação, foram desenvolvidos dez indicadores (KPIs) implementados por meio de consultas SQL diretamente sobre o Data Warehouse, contemplando aspectos como quadro de funcionários, remuneração, férias, licenças, composição organizacional, contratações, candidaturas e tempo de permanência. Os resultados demonstraram que a arquitetura desenvolvida atendeu aos requisitos propostos, integrando o processo de ETL, o modelo multidimensional e as consultas analíticas em

¹Centro Universitário Salesiano (Unisales). E-mail: matheus.veigar@souunisales.com.br.

²Centro Universitário Salesiano (Unisales). E-mail: KAYO.SILVA@souunisales.com.br.

³Centro Universitário Salesiano (Unisales). E-mail: ruan.silva@souunisales.com.br.

⁴Centro Universitário Salesiano (Unisales). E-mail: gabriel.goes@souunisales.com.br.

⁵Centro Universitário Salesiano (Unisales). E-mail: james.junior@souunisales.com.br.

uma estrutura orientada às necessidades do domínio de Recursos Humanos. Conclui-se que a solução desenvolvida possibilitou transformar dados transacionais em uma estrutura organizada para análise e apoio à tomada de decisão.

Palavras-chave: Data Warehouse; ETL incremental; Star Schema; Engenharia de Dados; KPIs.

ABSTRACT: This work presents the development of a Data Engineering solution applied to the Human Resources schema of the AdventureWorks database, used as a transactional source in SQL Server. The objective was to build a multidimensional Data Warehouse capable of organizing data for strategic analysis by adopting the Star Schema pattern and an incremental ETL process. The methodology comprised the analysis and mapping of the source relational model, the definition of the multidimensional model, its implementation in PostgreSQL, and the development of an ETL process in Python involving data extraction, intermediate persistence in CSV files, transformation, and loading into the Data Warehouse. For updates after the initial load, an incremental strategy based on record modification dates was adopted, with execution control through the *dw_metadata* table. To validate the solution, ten performance indicators (KPIs) were developed and implemented through SQL queries directly on the Data Warehouse, covering aspects such as employee headcount, compensation, vacation hours, medical leave, organizational structure, hiring, applications, and employee tenure. The results demonstrated that the developed architecture met the proposed requirements by integrating the ETL process, the multidimensional model, and analytical queries into a structure oriented toward Human Resources needs. It is concluded that the proposed solution enabled the transformation of transactional data into an organized analytical structure capable of supporting information analysis and decision-making.

Keywords: Data Warehouse; Incremental ETL; Star Schema; Data Engineering; KPIs.

1 INTRODUÇÃO

No cenário corporativo contemporâneo, a tomada de decisão baseada em dados deixou de ser um diferencial para se tornar uma necessidade estratégica. Sistemas transacionais (OLTP - Online Transaction Processing), embora altamente eficientes para o registro e a integridade de operações diárias, apresentam limitações de desempenho e complexidade quando submetidos a consultas analíticas profundas e agregações históricas (Elmasri; Navathe, 2011). É nesse contexto que os Data Warehouses (DW) se destacam, fornecendo uma arquitetura estruturalmente otimizada para o processamento analítico (OLAP - Online Analytical Processing) (Inmon, 2005).

O presente trabalho tem como objetivo projetar e implementar um Data Warehouse a partir do banco de dados relacional AdventureWorks, simulando um ambiente real de transição de dados operacionais para um modelo de inteligência de negócios. Para delimitar o escopo do projeto, conforme alinhamento prévio e permissão da orientação da disciplina, a análise e a modelagem foram restritas a um único domínio de dados da empresa, sendo escolhido o esquema de Recursos Humanos (Human Resources). A escolha desse setor justifica-se pela relevância estratégica da gestão de pessoas,

envolvendo métricas fundamentais como folha de pagamento, rotatividade, horas de licença e estrutura hierárquica.

Para alcançar os objetivos propostos, o desenvolvimento envolveu a análise do modelo OLTP original no SQL Server, a proposição de um modelo multidimensional no padrão Star Schema (Modelo Estrela) e a sua respectiva implementação em um banco de dados PostgreSQL. Além da modelagem, o trabalho destaca-se pela construção de um processo de ETL (Extract, Transform, Load) em Python com arquitetura de carga incremental, garantindo a atualização eficiente dos dados. Por fim, o modelo é validado através da implementação de 10 indicadores de desempenho (KPIs) via linguagem SQL, atestando a capacidade da nova estrutura em responder a perguntas complexas de negócio de forma ágil e otimizada.

2 FUNDAMENTAÇÃO TEÓRICA

Esta seção apresenta os conceitos centrais que embasam a arquitetura de dados desenvolvida neste projeto, focando na Modelagem Multidimensional e nos processos de integração de dados via ETL.

2.1 MODELAGEM MULTIDIMENSIONAL E STAR SCHEMA

Diferente da modelagem relacional (E-R), que busca a normalização extrema para evitar redundâncias e garantir a integridade das transações operacionais, a modelagem multidimensional é desenhada para a leitura rápida e a facilidade de navegação por grandes volumes de dados históricos. Segundo Kimball e Ross (2013), essa arquitetura divide as informações em duas categorias principais: Fatos e Dimensões.

As tabelas de Fato armazenam os eventos métricos e quantitativos do processo de negócio (ex: valores de salários, contagem de horas), possuindo chaves estrangeiras que apontam para o contexto em que aquele evento ocorreu. Já as tabelas de Dimensão armazenam os atributos qualitativos e descritivos (ex: dados do funcionário, departamento e calendário), fornecendo o contexto textual para a filtragem e o agrupamento das métricas da tabela fato (Machado, 2020).

O padrão adotado neste trabalho é o Star Schema (Modelo Estrela), amplamente utilizado na indústria pela sua simplicidade e alta performance. Nele, uma única tabela de fatos central é conectada diretamente a múltiplas tabelas de dimensão desnormalizadas, formando uma estrutura visual que remete a uma estrela (Golfarelli; Rizzi, 2009). Esse design minimiza o número de junções (JOINS) necessárias durante as consultas, acelerando drasticamente o tempo de resposta dos indicadores.

2.2 PROCESSOS DE ETL E CARGA INCREMENTAL

A sigla ETL refere-se às etapas de Extração, Transformação e Carga (Load), que compõem o fluxo de integração responsável por movimentar os dados do sistema de origem para o Data Warehouse (Kimball; Caserta, 2004). A extração atua na coleta dos dados brutos; a transformação aplica regras de negócio, limpezas e conversões; e a carga insere os dados refinados no ambiente de destino.

Em ambientes corporativos com alto volume de informações, realizar a carga total (Full Load) do banco de dados a cada ciclo de atualização torna-se inviável devido ao alto consumo de recursos de processamento e rede. Para solucionar esse problema, emprega-se a estratégia de carga incremental. Segundo Inmon (2005), essa abordagem tem como premissa processar e carregar apenas os registros que foram criados

ou modificados desde a última execução bem-sucedida do pipeline.

Para que isso seja possível, utilizam-se técnicas de controle de estado, como a implementação de watermarks (marcas temporais) gerenciadas através de tabelas de metadados. Essa técnica compara a data da última atualização registrada no DW com as datas de modificação (ModifiedDate) no sistema de origem, garantindo que o Data Warehouse seja mantido sincronizado de maneira eficiente.

3 METODOLOGIA


Esta seção detalha a arquitetura técnica adotada para o projeto, desde a análise do banco de dados relacional de origem até a construção da esteira de integração (ETL) e consolidação do modelo multidimensional. Todos os scripts, códigos da ETL em Python e o modelo de criação do Data Warehouse estão disponíveis no repositório oficial do projeto, acessível através do repositório oficial do projeto.

3.1 ANÁLISE DO MODELO OLTP E DECISÕES DE MODELAGEM

O ponto de partida do projeto foi a restauração e análise do banco de dados transacional (OLTP) AdventureWorks, da Microsoft. Para adequar o escopo do trabalho à construção de uma solução analítica focada, o grupo optou por trabalhar com o esquema de Recursos Humanos.

No modelo relacional original, os dados dos colaboradores e suas movimentações estão altamente normalizados, seguindo as regras clássicas de integridade transacional (Elmasri; Navathe, 2011). Informações sobre funcionários, departamentos, turnos, histórico de pagamentos e candidaturas encontram-se fragmentadas em diversas tabelas interligadas por relacionamentos complexos (conforme ilustrado na Figura 1). Embora otimizado para inserções, esse formato é ineficiente para totalizações e médias.

Figura 1 – Modelo relacional (OLTP) do esquema de Recursos Humanos do AdventureWorks




Fonte: Elaboração própria.

A decisão de modelagem consistiu em desnormalizar essas estruturas transacionais, consolidando os atributos descritivos e convertendo as métricas de RH em um formato otimizado para leitura.

3.2 ARQUITETURA DO MODELO MULTIDIMENSIONAL (STAR SCHEMA)

A partir da análise do OLTP, foi projetado um modelo multidimensional implementado no banco de dados PostgreSQL. Seguindo as diretrizes de Kimball e Ross (2013) para o padrão Star Schema, a arquitetura centraliza os eventos de recursos humanos na tabela de fatos *fhuman_resources*, que é rodeada por sete tabelas de dimensão que fornecem o contexto analítico unificado.

Figura 2 – Diagrama do modelo multidimensional (Star Schema) implementado no PostgreSQL



Fonte: Elaboração própria.

3.3 DICIONÁRIO DE DADOS DO DATA WAREHOUSE

A estrutura final do DW, em conformidade com as regras de negócio mapeadas pelo grupo, foi definida da seguinte maneira:

- **Tabela Fato (*fhuman_resources*):** Centraliza os eventos de RH. Armazena as chaves estrangeiras conectando-se a todas as dimensões e detém as métricas quantitativas de negócio: *rate* (taxa salarial), *vacationhours* (horas de férias) e *sickleavehours* (horas de licença médica).
- **Tabela *demployee*:** Dimensão que armazena os dados cadastrais, perfil qualitativo, status atual (*currentflag*), gênero e níveis organizacionais dos colaboradores.
- **Tabela *ddepartment*:** Dimensão nominal contendo as áreas, setores e o nome do grupo macro (*groupname*) da organização.
- **Tabelas *ddate* e *dtime*:** Dimensões cronológicas responsáveis por permitir análises e agrupamentos temporais de longo prazo e precisão intradiária, facilitando visões por ano e semestre.
- **Tabelas *dshift*, *djob_candidate* e *dpay_history*:** Dimensões que contextualizam, respectivamente, os turnos de trabalho, os currículos de candidaturas internas e a frequência da folha de pagamento.

3.4 ESTRATÉGIA DE ETL INCREMENTAL

A extração, transformação e carga dos dados foram desenvolvidas utilizando a linguagem Python. Após a extração dos dados originais e a persistência inicial em arquivos CSV, a carga no Data Warehouse foi estruturada para operar de forma estritamente incremental, processando apenas registros novos ou modificados, o que reduz drasticamente o tempo de processamento em janelas de atualização (Inmon, 2005).

Para sustentar essa arquitetura, foi implementada uma tabela de controle operacional chamada *dw_metadata* no banco PostgreSQL. Esta tabela atua isolada do Star Schema e é responsável por armazenar as *watermarks* (marcas temporais). O processo de ETL consulta o campo *last_load_date* dessa tabela para descobrir a data exata da última carga bem-sucedida. Com base nessa estampa de tempo, o script filtra na origem apenas os dados cuja data de modificação seja superior à *watermark* registrada. Ao fim de cada ciclo, a tabela *dw_metadata* é atualizada com a nova data e o volume de registros processados (*records_processed*).

3.5 IMPLEMENTAÇÃO E VALIDAÇÃO DOS INDICADORES (KPIs)

Para comprovar a eficiência do modelo multidimensional construído, o grupo elaborou 10 indicadores (KPIs) de negócio voltados à gestão de pessoas. As métricas foram desenvolvidas via consultas em linguagem SQL nativa no PostgreSQL diretamente sobre a tabela de fatos e suas dimensões.

Abaixo, detalhamos a validação visual e lógica dos scripts construídos para responder às perguntas de negócio do RH.

KPI 1: Total de Funcionários Ativos

Monitora o tamanho real do quadro de colaboradores filtrando a flag de status ativo.

Figura 3 – Validação do KPI 1 – Total de Funcionários Ativos

```
/*
=====
PROJETO DE DATA WAREHOUSE - RECURSOS HUMANOS (STAR SCHEMA)
VALIDAÇÃO DOS 10 INDICADORES DE NEGÓCIO (KPIs)
=====
Este script contém as consultas analíticas (OLAP) oficiais para homologação do DW.
Todas as consultas foram validadas e corrigidas segundo a sintaxe do PostgreSQL.
===== */

--
-- KPI 1: TOTAL DE FUNCIONÁRIOS ATIVOS
-- Objetivo: Monitorar o tamanho real e atual do quadro de colaboradores da empresa.
-- Métrica: Contagem distinta de funcionários cujo status de atividade está marcado como ativo (1).
--
SELECT
    COUNT(DISTINCT employeeid) AS total_funcionarios_ativos
FROM
    employee
WHERE
    currentflag = 1;
```

Fonte: Elaboração própria.

KPI 2: Gasto Total da Folha de Pagamento por Hora

Avalia o impacto financeiro imediato consolidando a métrica salarial da tabela fato.

Figura 4 – Validação do KPI 2 – Gasto Total da Folha de Pagamento por Hora

```
-- KPI 2: CUSTO TOTAL DA FOLHA DE PAGAMENTO POR HORA (RATE)
-- Objetivo: Avaliar o impacto financeiro imediato do custo operacional de pessoal por hora.
-- Métrica: Somatório simples de todas as taxas salariais (rate) contidas na tabela fato.

SELECT
    SUM(rate) AS custo_total_folha_por_hora
FROM
    fhuman_resources;
```

Fonte: Elaboração própria.

KPI 3: Média Salarial por Cargo

Analisa a competitividade e a discrepância de remuneração entre as funções agrupando os dados pela dimensão de empregado.

Figura 5 – Validação do KPI 3 – Média Salarial por Cargo

```
-- KPI 3: MÉDIA SALARIAL (RATE) POR CARGO
-- Objetivo: Analisar a competitividade interna de remuneração e disparidades entre funções.
-- Métrica: Média aritmética do campo rate agrupada pelo título descritivo do cargo (jobtitle).

SELECT
    e.jobtitle AS cargo,
    ROUND(AVG(f.rate), 2) AS media_salarial_por_hora
FROM
    fhuman_resources f
JOIN
    employee e ON f.employeeid = e.employeeid
GROUP BY
    e.jobtitle
ORDER BY
    media_salarial_por_hora DESC;
```

Fonte: Elaboração própria.

KPI 4: Média de Horas de Férias Acumuladas por Departamento

Indicador fundamental para identificar possíveis passivos trabalhistas ou setores operacionais sobrecarregados.

Figura 6 – Validação do KPI 4 – Média de Horas de Férias Acumuladas por Departamento

```
-- KPI 4: MÉDIA DE HORAS DE FÉRIAS ACUMULADAS POR DEPARTAMENTO
-- Objetivo: Identificar passivos trabalhistas ou setores sobrecarregados com falta de descanso.
-- Métrica: Média das horas de férias registradas na fato, agrupada por nome do departamento.

SELECT
    d.name AS departamento,
    ROUND(AVG(f.vacationhours), 1) AS media_horas_ferias_pendentes
FROM
    fhuman_resources f
JOIN
    department d ON f.departmentid = d.departmentid
GROUP BY
    d.name
ORDER BY
    media_horas_ferias_pendentes DESC;
```

Fonte: Elaboração própria.

KPI 5: Total de Horas de Licença Médica por Turno de Trabalho

Mede o índice de absenteísmo por motivos de saúde, cruzando os registros de licença com os turnos cadastrados.

Figura 7 – Validação do KPI 5 – Total de Horas de Licença Médica por Turno de Trabalho

```

-- KPI 5: TOTAL DE HORAS DE LICENÇA MÉDICA POR TURNO DE TRABALHO
-- Objetivo: Medir o índice de absenteísmo por motivos de saúde correlacionado ao período/turno.
-- Métrica: Soma total das horas de licença médica agrupadas pela classificação qualitativa do turno.
-----
SELECT
    s.name AS turno,
    SUM(f.sickleavehours) AS total_horas_licenca_medica
FROM
    fhuman_resources f
JOIN
    dshift s ON f.shiftid = s.shiftid
GROUP BY
    s.name
ORDER BY
    total_horas_licenca_medica DESC;

```

Fonte: Elaboração própria.

KPI 6: Distribuição Percentual de Funcionários por Gênero e Departamento

Apoia políticas de diversidade e inclusão quantificando a distribuição de gênero dentro dos setores.

Figura 8 – Validação do KPI 6 – Distribuição Percentual de Funcionários por Gênero e Departamento

```

-- KPI 6: DISTRIBUIÇÃO E PERCENTUAL DE FUNCIONÁRIOS POR GÊNERO EM CADA DEPARTAMENTO
-- Objetivo: Fornecer dados quantitativos para apoiar políticas de diversidade e inclusão por setor.
-- Métrica: Contagem de funcionários dividida por gênero com cálculo percentual dinâmico usando Window Function.
-----
SELECT
    d.name AS departamento,
    e.gender AS genero,
    COUNT(DISTINCT f.employeeid) AS total_colaboradores,
    ROUND(
        COUNT(DISTINCT f.employeeid) * 100.0 / SUM(COUNT(DISTINCT f.employeeid)) OVER(PARTITION BY d.name),
        2
    ) AS percentual_no_departamento
FROM
    fhuman_resources f
JOIN
    ddepartment d ON f.departmentid = d.departmentid
JOIN
    demployee e ON f.employeeid = e.employeeid
GROUP BY
    d.name, e.gender
ORDER BY
    d.name, e.gender;

```

Fonte: Elaboração própria.

KPI 7: Evolução Histórica de Contratações por Ano e Semestre

Avalia o ritmo e a tração do recrutamento ao longo do tempo utilizando a dimensão cronológica do DW.

Figura 9 – Validação do KPI 7 – Evolução Histórica de Contratações por Ano e Semestre

```
-- -----  
-- KPI 7: EVOLUÇÃO HISTÓRICA DO TOTAL DE CONTRATAÇÕES POR ANO E SEMESTRE  
-- Objetivo: Analisar o ritmo de crescimento e a tração de novos talentos ao longo do tempo.  
-- Métrica: Contagem do total de registros agregados pelas partições cronológicas da dimensão ddate.  
-- -----  
SELECT  
    d.year AS ano,  
    d.semester AS semestre,  
    COUNT(f.fhumanresources) AS total_admissoes  
FROM  
    fhuman_resources f  
JOIN  
    ddate d ON f.dateid = d.dateid  
GROUP BY  
    d.year, d.semester  
ORDER BY  
    ano DESC, semestre DESC;
```

Fonte: Elaboração própria.

KPI 8: Comparação da Maior Remuneração por Nível Organizacional

Entende o comportamento do teto salarial à medida que se sobe na hierarquia (senioridade) corporativa.

Figura 10 – Validação do KPI 8 – Comparação da Maior Remuneração por Nível Organizacional

```
-- -----  
-- KPI 8: COMPARAÇÃO DA MAIOR REMUNERAÇÃO (RATE) POR NÍVEL ORGANIZACIONAL (HIERARQUIA)  
-- Objetivo: Entender a correlação entre a senioridade/nível de liderança com o teto salarial.  
-- Métrica: Valor máximo da taxa (rate) encontrado para cada degrau da estrutura hierárquica.  
-- -----  
SELECT  
    COALESCE(e.organizationlevel::text, 'Nível Topo/Diretoria') AS nivel_hierarquico,  
    MAX(f.rate) AS maior_taxa_salarial  
FROM  
    fhuman_resources f  
JOIN  
    employee e ON f.employeeid = e.employeeid  
GROUP BY  
    e.organizationlevel  
ORDER BY  
    maior_taxa_salarial DESC;
```

Fonte: Elaboração própria.

KPI 9: Total de Candidatos com Currículo Capturado por Departamento

Avalia a eficiência e a atratividade do banco de talentos para cada área de negócio, contabilizando apenas os registros de candidatos válidos.

Figura 11 – Validação do KPI 9 – Total de Candidatos com Currículo Capturado por Departamento

```
-- KPI 9: TOTAL DE CANDIDATOS COM CURRÍCULO CAPTURADO POR DEPARTAMENTO
-- Objetivo: Avaliar a eficiência e a atratividade do banco de talentos para cada área de negócio.
-- Métrica: Contagem de chaves de candidatos válidas (removendo registros nulos) associadas a cada setor.
-----
SELECT
    d.name AS departamento,
    COUNT(f.jobcandidateid) AS total_curriculos_recebidos
FROM
    fhuman_resources f
JOIN
    ddepartment d ON f.departmentid = d.departmentid
WHERE
    f.jobcandidateid IS NOT NULL
GROUP BY
    d.name
ORDER BY
    total_curriculos_recebidos DESC;
```

Fonte: Elaboração própria.

KPI 10: Média de Tempo de Casa (em Anos) por Título de Cargo

Analisa os padrões de retenção de talentos e o tempo de permanência por função, calculando a diferença cronológica entre a data de admissão e o momento atual.

Figura 12 – Validação do KPI 10 – Média de Tempo de Casa por Título de Cargo

```
-- KPI 10: MÉDIA DE TEMPO DE CASA (EM ANOS) POR TÍTULO DE CARGO
-- Objetivo: Analisar os padrões de retenção de talentos e o tempo de permanência por função.
-- Métrica: Diferença em anos calculada entre a data de admissão (hiredate) e a data corrente do sistema.
-----
SELECT
    e.jobtitle AS cargo,
    ROUND(AVG(EXTRACT(YEAR FROM AGE(CURRENT_DATE, e.hiredate))))::numeric, 1) AS media_anos_tempo_de_casa
FROM
    fhuman_resources f
JOIN
    demployee e ON f.employeeid = e.employeeid
GROUP BY
    e.jobtitle
ORDER BY
    media_anos_tempo_de_casa DESC;
```

Fonte: Elaboração própria.

4 RESULTADOS E DISCUSSÃO

Os resultados obtidos a partir do desenvolvimento do projeto demonstram a aplicação integrada de conceitos de Engenharia de Dados, modelagem multidimensional, processos de ETL e definição de indicadores de desempenho. A solução construída teve como ponto de partida o banco de dados AdventureWorks, disponibilizado pela Microsoft e estruturado em SQL Server, utilizado como ambiente transacional (OLTP). A partir da análise desse modelo relacional, foram realizados o mapeamento das estruturas e a definição de um modelo multidimensional destinado à análise dos dados de Recursos Humanos.

4.1 RESULTADOS DA ANÁLISE E MODELAGEM DOS DADOS

A análise inicial do banco AdventureWorks possibilitou identificar as estruturas relacionais que compõem o esquema de Recursos Humanos e compreender os relacionamentos existentes entre os diferentes conjuntos de dados. Esse levantamento serviu como base para a definição das entidades, atributos e métricas necessárias à construção do Data Warehouse.

No ambiente OLTP, as informações encontram-se distribuídas em diferentes tabelas,

seguindo uma estrutura orientada às operações transacionais. A partir desse levantamento, foi realizada a seleção dos dados relevantes ao escopo do projeto e o mapeamento das colunas que seriam utilizadas na solução analítica. A Figura 1 apresenta o modelo relacional utilizado como origem para o processo de transformação.

Com base nessa análise, foi elaborado um modelo multidimensional no PostgreSQL seguindo o padrão Star Schema. A nova estrutura foi projetada de forma a centralizar os eventos relacionados aos recursos humanos em uma tabela fato e organizá-los segundo dimensões responsáveis por fornecer os diferentes contextos de análise.

A Figura 2 apresenta o modelo multidimensional implementado no PostgreSQL. Em comparação com a estrutura original, observa-se a reorganização das informações em uma arquitetura orientada à consulta analítica, com a tabela *fhuman_resources* relacionada às dimensões de empregado, departamento, data, horário, turno, candidatura e histórico de pagamento.

A mudança de uma estrutura relacional orientada às operações para uma estrutura dimensional orientada à análise permitiu reduzir a complexidade necessária para consultar informações de diferentes áreas do domínio de Recursos Humanos. Dessa forma, atributos descritivos e métricas passaram a estar organizados segundo as necessidades de análise definidas no projeto.

4.2 RESULTADOS DA IMPLEMENTAÇÃO DO PROCESSO DE ETL

Após a definição do modelo multidimensional, foi implementado o processo de extração, transformação e carga dos dados utilizando a linguagem Python. A extração teve como origem o banco de dados AdventureWorks em SQL Server, de onde os registros selecionados foram obtidos e posteriormente persistidos em arquivos no formato CSV.

A utilização dos arquivos CSV como etapa intermediária permitiu realizar a manipulação e transformação dos dados antes de sua inserção definitiva no Data Warehouse. Nessa etapa, os dados foram adequados às estruturas e aos tipos definidos para o modelo multidimensional implementado no PostgreSQL.

Após as etapas de transformação, os dados foram carregados nas tabelas correspondentes do Data Warehouse. Esse processo permitiu estabelecer uma separação entre a base transacional de origem e o ambiente destinado às consultas analíticas, mantendo o PostgreSQL como repositório dos dados transformados.

Um dos principais resultados do projeto foi a implementação de uma estratégia de carga incremental. Na primeira execução, por se tratar da carga inicial, os dados necessários foram processados integralmente. Nas execuções posteriores, o processo passou a considerar apenas os registros novos ou modificados, utilizando a data de modificação registrada na origem como critério para determinar quais dados deveriam ser processados.

Para controlar esse comportamento, foi utilizada a tabela *dw_metadata*, responsável pelo armazenamento da *watermark* da execução. O processo consulta o campo *last_load_date* para identificar o momento correspondente à última carga processada e, a partir dessa informação, determina o conjunto de registros que deverá ser considerado na execução seguinte.

Ao final do processo, a tabela de controle é atualizada com a nova marca temporal e com o volume de registros processados por meio do campo *records_processed*. Esse

mecanismo permite acompanhar as execuções e manter o processo de integração de forma incremental, evitando o recarregamento desnecessário de todos os dados a cada atualização.

A estratégia adotada atende, portanto, ao requisito central de incrementalidade estabelecido para o projeto, uma vez que o comportamento da ETL foi estruturado para diferenciar a carga inicial das cargas subsequentes e processar apenas os registros que sofreram alterações ou foram adicionados após a última execução.

4.3 RESULTADOS DA IMPLEMENTAÇÃO DOS INDICADORES

Com o Data Warehouse devidamente estruturado e carregado, foram desenvolvidas consultas SQL diretamente no PostgreSQL para validar o funcionamento do modelo e responder às perguntas de negócio definidas para o domínio de Recursos Humanos.

Foram elaborados dez indicadores de desempenho (KPIs), cada um associado a uma necessidade específica de análise. A implementação dessas consultas demonstrou a capacidade do modelo dimensional de combinar as métricas armazenadas na tabela fato com os atributos presentes nas dimensões.

O primeiro indicador, apresentado na Figura 3, corresponde ao total de funcionários ativos. Sua implementação utiliza o status dos colaboradores para identificar a quantidade de registros atualmente classificados como ativos, fornecendo uma visão objetiva da composição do quadro funcional.

Na Figura 4, é apresentada a consulta referente ao gasto total da folha de pagamento por hora. O indicador utiliza a informação de remuneração disponível na tabela fato para consolidar o valor associado à folha, demonstrando a aplicação de uma métrica financeira sobre a estrutura dimensional.

A Figura 5 apresenta o indicador de média salarial por cargo. Nesse caso, a consulta relaciona os valores de remuneração aos títulos dos cargos armazenados na dimensão de empregados, permitindo comparar o comportamento da remuneração entre diferentes funções.

O quarto indicador, apresentado na Figura 6, calcula a média de horas de férias acumuladas por departamento. A consulta combina a métrica correspondente às horas de férias com os atributos da dimensão departamental, possibilitando observar a distribuição do indicador entre as diferentes áreas da organização.

Na Figura 7, encontra-se o indicador de total de horas de licença médica por turno de trabalho. A consulta utiliza a dimensão de turnos para segmentar os registros e relacionar as informações de afastamento aos respectivos períodos de trabalho.

O sexto indicador, apresentado na Figura 8, corresponde à distribuição percentual de funcionários por gênero e departamento. A consulta demonstra a possibilidade de combinar mais de uma dimensão em uma mesma análise, permitindo segmentar os colaboradores simultaneamente pelos atributos de gênero e departamento.

A Figura 9 apresenta a evolução histórica de contratações por ano e semestre. O indicador utiliza a dimensão temporal do Data Warehouse para organizar os registros segundo diferentes períodos, demonstrando a aplicação da modelagem dimensional em análises históricas.

O oitavo indicador, apresentado na Figura 10, corresponde à comparação da maior

remuneração por nível organizacional. A consulta utiliza o atributo de nível hierárquico disponível na dimensão de empregados para relacioná-lo aos valores de remuneração e identificar o maior valor observado em cada nível.

Na Figura 11, é apresentada a análise do total de candidatos com currículo capturado por departamento. O indicador relaciona os registros de candidatos às informações departamentais, possibilitando identificar a distribuição dos candidatos entre as diferentes áreas da organização.

Por fim, a Figura 12 apresenta a média de tempo de casa, em anos, por título de cargo. A consulta utiliza a data de admissão dos colaboradores em conjunto com o título de suas funções para calcular o tempo de permanência e obter uma visão segmentada por cargo.

4.4 DISCUSSÃO DOS RESULTADOS OBTIDOS

A implementação dos dez KPIs demonstrou que o Data Warehouse desenvolvido foi capaz de atender às necessidades analíticas estabelecidas para o esquema de Recursos Humanos. As consultas foram executadas diretamente sobre o modelo multidimensional, utilizando os relacionamentos entre a tabela fato e as dimensões para produzir diferentes perspectivas de análise.

Os indicadores contemplam diferentes categorias de informação, incluindo quadro de colaboradores, remuneração, férias, licenças, composição organizacional, contratações, recrutamento e permanência dos funcionários. Essa diversidade demonstra que o modelo construído não foi direcionado a apenas uma métrica isolada, mas estruturado para suportar diferentes necessidades de análise dentro do domínio selecionado.

Outro resultado relevante foi a possibilidade de utilizar diferentes dimensões para detalhar as mesmas métricas. Informações de remuneração, por exemplo, podem ser analisadas segundo cargo e nível organizacional, enquanto dados relacionados aos colaboradores podem ser segmentados por departamento, gênero ou turno. Essa característica é uma consequência direta da organização dimensional adotada no projeto.

A implementação da ETL incremental também representa um resultado importante, pois estabelece uma estratégia de atualização diferente da simples recarga completa do Data Warehouse. Após a carga inicial, o processo passa a utilizar a data de modificação dos registros para identificar apenas os dados que precisam ser processados. Essa abordagem reduz o trabalho realizado nas execuções subsequentes e torna o processo de atualização mais compatível com uma rotina periódica de integração de dados (Inmon, 2005).

A utilização de uma tabela de controle separada do Star Schema contribui ainda para a organização do processo operacional da ETL. A tabela *dw_metadata* mantém as informações necessárias ao acompanhamento das cargas sem interferir diretamente na estrutura dimensional utilizada pelas consultas analíticas.

De maneira geral, os resultados demonstram que a solução desenvolvida cumpriu os principais requisitos estabelecidos para o trabalho: a análise do banco AdventureWorks em seu modelo OLTP, a elaboração de um modelo multidimensional no padrão Star Schema, a implementação do Data Warehouse no PostgreSQL, a construção de uma ETL incremental em Python e a implementação de dez indicadores por

meio de consultas SQL.

A integração desses componentes resultou em uma arquitetura na qual os dados transacionais são extraídos, transformados e reorganizados em uma estrutura analítica, permitindo posteriormente sua utilização em consultas orientadas às necessidades de negócio. Dessa forma, o projeto evidencia a aplicação prática dos conceitos de Engenharia de Dados e de modelagem multidimensional no desenvolvimento de uma solução de Data Warehouse.

5 CONSIDERAÇÕES FINAIS

O desenvolvimento deste trabalho possibilitou aplicar, de forma integrada, conceitos de Engenharia de Dados, processos de ETL incremental e modelagem multidimensional em uma solução de Data Warehouse voltada ao domínio de Recursos Humanos. A partir do banco de dados AdventureWorks, utilizado como fonte transacional em SQL Server, foi realizada a análise do modelo relacional e o mapeamento das estruturas necessárias para a construção de uma arquitetura analítica no PostgreSQL.

A adoção do padrão Star Schema permitiu reorganizar os dados selecionados do modelo OLTP em uma estrutura orientada à análise, centralizando os eventos de recursos humanos na tabela de fatos e distribuindo os atributos descritivos entre as dimensões correspondentes. Essa organização possibilitou estruturar diferentes perspectivas de consulta e reduzir a complexidade necessária para a obtenção das informações utilizadas nos indicadores desenvolvidos.

A implementação da ETL em Python também constituiu uma contribuição relevante do projeto. O processo foi estruturado em etapas de extração dos dados do ambiente transacional, persistência intermediária em arquivos CSV, transformação das informações e posterior carregamento no Data Warehouse. A adoção da estratégia incremental permitiu diferenciar a carga inicial das execuções subsequentes, utilizando a data de modificação dos registros para processar apenas os dados novos ou modificados. O controle dessas execuções por meio da tabela *dw_metadata* possibilitou manter uma referência da última carga realizada e do volume de registros processados.

A implementação dos dez indicadores por meio de consultas SQL diretamente sobre o Data Warehouse demonstrou a capacidade da arquitetura desenvolvida em atender diferentes necessidades de análise relacionadas aos recursos humanos. Os KPIs contemplaram aspectos como quantidade de funcionários ativos, remuneração, férias, licenças médicas, distribuição por gênero e departamento, evolução das contratações, níveis organizacionais, candidatos e tempo de permanência por cargo.

Dessa forma, o trabalho alcançou os objetivos estabelecidos ao combinar a análise de uma base de dados transacional com a construção de uma estrutura multidimensional, um processo de integração incremental e um conjunto de indicadores orientados às necessidades de negócio. A solução também proporcionou a integração entre diferentes tecnologias, utilizando o SQL Server como ambiente de origem, Python na implementação da ETL e PostgreSQL como plataforma para o Data Warehouse e execução das consultas analíticas.

Como possibilidade de continuidade, trabalhos futuros poderão ampliar a solução desenvolvida por meio da incorporação de novos indicadores e dimensões, da utilização de mecanismos adicionais de monitoramento e auditoria das cargas e da integração com ferramentas de visualização de dados. Também poderá ser avaliado o compor-

tamento da solução em conjuntos de dados maiores e em cenários com atualizações mais frequentes, permitindo analisar sua capacidade de escalabilidade e desempenho em condições mais próximas de ambientes reais de produção.

Por fim, o projeto demonstra que a aplicação conjunta da modelagem multidimensional, da ETL incremental e da definição de indicadores pode transformar dados transacionais em uma estrutura organizada para análise, contribuindo para a disponibilização de informações de apoio à tomada de decisão no contexto de Recursos Humanos.

REFERÊNCIAS

ELMASRI, R.; NAVATHE, S. B. **Sistemas de banco de dados**. 6. ed. São Paulo: Pearson Addison Wesley, 2011.

GOLFARELLI, M.; RIZZI, S. **Data warehouse design: modern principles and methodologies**. New York: McGraw-Hill, 2009.

INMON, W. H. **Building the data warehouse**. 4. ed. Indianapolis: John Wiley & Sons, 2005.

KIMBALL, R.; CASERTA, J. **The data warehouse ETL toolkit: practical techniques for extracting, cleaning, conforming, and delivering data**. Indianapolis: Wiley, 2004.

KIMBALL, R.; ROSS, M. **The data warehouse toolkit: the definitive guide to dimensional modeling**. 3. ed. Indianapolis: John Wiley & Sons, 2013.

MACHADO, F. N. R. **Banco de Dados: Projeto e Implementação**. 4. ed. São Paulo: Érica, 2020.